Test de Jeffreys pour la validation des modèles de probabilité de défaut

DOFFOU Eve Roxane
DABGO Jean Franck Silvère

Projet du Cours de Statistique Mathématique (Christophe HURLIN) - Master ESA

Université d'Orléans

17 janvier 2026





Plan de la présentation

1 Introduction et Contexte Réglementaire

Plan de la présentation

1. Introduction et Contexte Réglementaire
2. Principe bayésien et test de Jeffreys
   - La distribution a priori de Jeffreys
   - Le lien avec l'information de Fisher
   - La loi a posteriori de Jeffreys
   - Intervalles de crédibilité
   - Le Paradoxe de Jeffreys-Lindley

Plan de la présentation

1. Introduction et Contexte Réglementaire
2. Principe bayésien et test de Jeffreys
   - La distribution a priori de Jeffreys
   - Le lien avec l'information de Fisher
   - La loi a posteriori de Jeffreys
   - Intervalles de crédibilité
   - Le Paradoxe de Jeffreys-Lindley
3. Application à la validation des modèles de PD

Plan de la présentation

1. Introduction et Contexte Réglementaire
2. Principe bayésien et test de Jeffreys
   - La distribution a priori de Jeffreys
   - Le lien avec l'information de Fisher
   - La loi a posteriori de Jeffreys
   - Intervalles de crédibilité
   - Le Paradoxe de Jeffreys-Lindley
3. Application à la validation des modèles de PD
4. Illustration empirique sous python

Plan de la présentation

1. Introduction et Contexte Réglementaire
2. Principe bayésien et test de Jeffreys
   - La distribution a priori de Jeffreys
   - Le lien avec l'information de Fisher
   - La loi a posteriori de Jeffreys
   - Intervalles de crédibilité
   - Le Paradoxe de Jeffreys-Lindley
3. Application à la validation des modèles de PD
4. Illustration empirique sous python
5. Limites du test de Jeffreys et conclusion

Introduction et Contexte Réglementaire

1.Rôle de la validation (Bâle II/III)

- **Importance :** Le modèle de probabilité de défaut (PD) et sa calibration sont au cœur de la gestion des risques bancaires.

1. Internal Ratings-Based

1.Rôle de la validation (Bâle II/III)

- **Importance :** Le modèle de probabilité de défaut (PD) et sa calibration sont au cœur de la gestion des risques bancaires.
- **Autonomie :** Les banques développent leurs propres modèles de Probabilité de Défaut (PD) via l'approche **IRB** [1] des accords de Bâle II et III.

1. Internal Ratings-Based

1.Rôle de la validation (Bâle II/III)

- **Importance :** Le modèle de probabilité de défaut (PD) et sa calibration sont au cœur de la gestion des risques bancaires.
- **Autonomie :** Les banques développent leurs propres modèles de Probabilité de Défaut (PD) via l'approche **IRB** [1] des accords de Bâle II et III.
- **Exigence BCE :** Nécessité d'une **calibration** précise (les prédictions doivent refléter les taux de défaut observés).

1. Internal Ratings-Based

1.Rôle de la validation (Bâle II/III)

- **Importance :** Le modèle de probabilité de défaut (PD) et sa calibration sont au cœur de la gestion des risques bancaires.
- **Autonomie :** Les banques développent leurs propres modèles de Probabilité de Défaut (PD) via l'approche **IRB** [1] des accords de Bâle II et III.
- **Exigence BCE :** Nécessité d'une **calibration** précise (les prédictions doivent refléter les taux de défaut observés).
- **Enjeux financiers :**
  - *Sous-estimation :* Insuffisance de fonds propres (risque systémique).
  - *Sur-estimation :* Perte de compétitivité (coût du capital trop élevé).

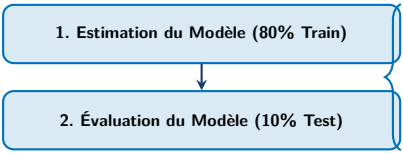
1. Internal Ratings-Based

2.Synthèse du Processus de Modélisation du Risque

L'approche IRB se décline en trois étapes fondamentales :

2.Synthèse du Processus de Modélisation du Risque

L'approche IRB se décline en trois étapes fondamentales :



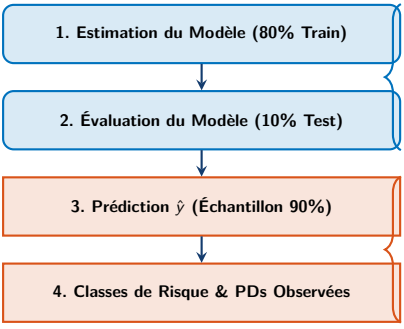
PHASE 1 : Différenciation du risque

Conception du modèle pour calculer des probailités de défauts individuelles conditionnelles PD_i.

$\rightarrow$ *Estimer la PD conditionnelle.*

2.Synthèse du Processus de Modélisation du Risque

L'approche IRB se décline en trois étapes fondamentales :



PHASE 1 : Différenciation du risque
Conception du modèle pour calculer des probailités de défauts individuelles conditionnelles PD_i.

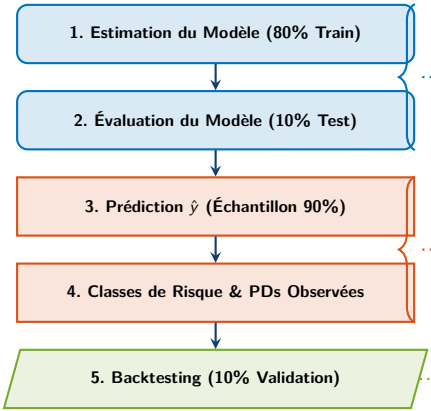
→ *Estimer la PD conditionnelle.*

PHASE 2 : Quantification du risque
Transformation les PPD_i en probabilité de défaut (PD) calibrée par classe.

→ *Vision Through-The-Cycle (LRA).*

2.Synthèse du Processus de Modélisation du Risque

L'approche IRB se décline en trois étapes fondamentales :



PHASE 1 : Différenciation du risque
Conception du modèle pour calculer des probabilités de défauts individuelles conditionnelles PD_i.
→ *Estimer la PD conditionnelle.*

PHASE 2 : Quantification du risque
Transformation les PPD_i en probabilité de défaut (PD) calibrée par classe.
→ *Vision Through-The-Cycle (LRA).*

PHASE 3 : Validation
Vérification de la performance sur des données vierges (Out-of-sample).
→ *Robustesse & Backtesting.*

3.Méthodes Fréquentistes de Calibration (Backtesting)

Repose sur la comparaison entre PD_k et pk estimé par $\hat{p}_k = \frac{d_k}{n_k}$.

3.Méthodes Fréquentistes de Calibration (Backtesting)

Repose sur la comparaison entre PD_k et pk estimé par $\hat{p}_k = \frac{d_k}{n_k}$.

1. Test Binomial et Approx. Normale

Pour de grands échantillons.
Sous $H_0 : p_k = PD_k$:

$$Z_k = \frac{\hat{p}_k - PD_k}{\sqrt{\frac{PD_k(1-PD_k)}{n_k}}} \sim \mathcal{N}(0,1)$$

Intervalle de confiance :

$$IC_{1-\alpha} = \hat{p}_k \pm \Phi^{-1}\left(1 - \tfrac{\alpha}{2}\right)\sqrt{\tfrac{PD_k(1-PD_k)}{n_k}}$$

3.Méthodes Fréquentistes de Calibration (Backtesting)

Repose sur la comparaison entre PD_k et pk estimé par $\hat{p}_k = \frac{d_k}{n_k}$.

1. Test Binomial et Approx. Normale

Pour de grands échantillons.
Sous $H_0 : p_k = PD_k$:

$$Z_k = \frac{\hat{p}_k - PD_k}{\sqrt{\frac{PD_k(1-PD_k)}{n_k}}} \sim \mathcal{N}(0,1)$$

Intervalle de confiance :

$$IC_{1-\alpha} = \hat{p}_k \pm \Phi^{-1}\left(1 - \tfrac{\alpha}{2}\right)\sqrt{\tfrac{PD_k(1-PD_k)}{n_k}}$$

2. Intervalle Exact de Clopper-Pearson

Pour les portefeuilles à faible défaut (LDP).[a]
Les bornes $[p_L, p_U]$ reposent sur la loi Bêta :

$$P(D \geq d_k \mid p = p_L) = \tfrac{\alpha}{2}$$
$$P(D \leq d_k \mid p = p_U) = \tfrac{\alpha}{2}$$

a. Low Default Portfolios

3.Limites des méthodes fréquentistes et Perspectives

Les méthodes fréquentistes présentent des faiblesses structurelles résumées ci-dessous :

Approximation Normale :

- Basée sur la loi binomiale asymptotique
- **Echec** : Risque de sous-couverture flagrante sur les petits échantillons ou faibles défauts(ou nul)

2. Exigence de reporting de surveillance des modèles internes de la BCE.

3.Limites des méthodes fréquentistes et Perspectives

Les méthodes fréquentistes présentent des faiblesses structurelles résumées ci-dessous :

Approximation Normale :

- Basée sur la loi binomiale asymptotique
- **Echec** : Risque de sous-couverture flagrante sur les petits échantillons ou faibles défauts(ou nul)

Clopper-Pearson :

- Test "exact"
- **Echec** : Risque de sur-couverture (conservatisme excessif) dû à la nature discrète de la loi binomiale

2. Exigence de reporting de surveillance des modèles internes de la BCE.

3.Limites des méthodes fréquentistes et Perspectives

Les méthodes fréquentistes présentent des faiblesses structurelles résumées ci-dessous :

Approximation Normale :

- Basée sur la loi binomiale asymptotique
- **Echec** : Risque de sous-couverture flagrante sur les petits échantillons ou faibles défauts(ou nul)

Clopper-Pearson :

- Test "exact"
- **Echec** : Risque de sur-couverture (conservatisme excessif) dû à la nature discrète de la loi binomiale

La BCE exige une alternative robuste : Le test de Jeffreys (particulièrement **la p-value**)[2].

2. Exigence de reporting de surveillance des modèles internes de la BCE.

3.Limites des méthodes fréquentistes et Perspectives

Les méthodes fréquentistes présentent des faiblesses structurelles résumées ci-dessous :

Approximation Normale :

- Basée sur la loi binomiale asymptotique
- **Echec** : Risque de sous-couverture flagrante sur les petits échantillons ou faibles défauts(ou nul)

Clopper-Pearson :

- Test "exact"
- **Echec** : Risque de sur-couverture (conservatisme excessif) dû à la nature discrète de la loi binomiale

La BCE exige une alternative robuste : Le test de Jeffreys (particulièrement **la p-value**)[2].

Cette approche considère p_k comme une variable aléatoire continue et s'avère bien plus robuste pour les portefeuilles avec très peu (ou Zéro) de défauts constatés.

2. Exigence de reporting de surveillance des modèles internes de la BCE.

Principe bayésien et test de Jeffreys

1. Principe du test de Jeffreys

Point de départ : le théorème de Bayes

$$\pi(p_k \mid y) = \frac{\pi(y \mid p_k)\,\pi(p_k)}{\pi(y)}$$

où $\pi(p_k)$ est la loi a priori, $\pi(p_k \mid y)$ la loi a posteriori et $\pi(y \mid p_k)$ la fonction de vraisemblance décrivant la probabilité d'observer $y = \{y_1 \dots y_n\}$ étant donné p_k.

1. Principe du test de Jeffreys

Point de départ : le théorème de Bayes

$$\pi(p_k \mid y) = \frac{\pi(y \mid p_k)\,\pi(p_k)}{\pi(y)}$$

où $\pi(p_k)$ est la loi a priori, $\pi(p_k \mid y)$ la loi a posteriori et $\pi(y \mid p_k)$ la fonction de vraisemblance décrivant la probabilité d'observer $y = \{y_1 \dots y_n\}$ étant donné p_k.

La distribution a priori de Jeffreys (1946, 1961)

Si $Y_i \sim \text{Bernoulli}(p_k)$ (défaut / non-défaut), avec $p_k \in [0, 1]$, l'a priori de Jeffreys est :

$$p_k \sim \text{Beta}\left(\tfrac{1}{2}, \tfrac{1}{2}\right).$$

2. A priori de Jeffreys via l'information de Fisher

La loi a priori de Jeffreys est construite à partir de l'**information de Fisher** $I(p)$.

Information de Fisher (Bernoulli / Binomiale)

Pour n observations de Bernoulli (ou une binomiale), on obtient :

$$I(p_k) = \mathbb{E}\left[-\frac{\partial^2}{\partial\theta^2}\log\pi(Y \mid p_k)\right] = \frac{n}{p_k(1-p_k)}.$$

2. A priori de Jeffreys via l'information de Fisher

La loi a priori de Jeffreys est construite à partir de l'**information de Fisher** $I(p)$.

Information de Fisher (Bernoulli / Binomiale)

Pour n observations de Bernoulli (ou une binomiale), on obtient :

$$I(p_k) = \mathbb{E}\left[-\frac{\partial^2}{\partial\theta^2}\log\pi(Y \mid p_k)\right] = \frac{n}{p_k(1-p_k)}.$$

L'a priori de Jeffreys est proportionnel à la racine de l'information de Fisher :

$$\pi(p_k) \propto \sqrt{I(p_k)} \quad \Rightarrow \quad p_k \sim \mathrm{Beta}\left(\tfrac{1}{2}, \tfrac{1}{2}\right).$$

3. Loi a posteriori (conjugaison Bêta–Binomiale)

On observe d_k défauts sur n_k expositions (classe/segment k).

Posterior

Comme l'a priori de Jeffreys est conjugué à la vraisemblance binomiale :

$$p_k \mid y \sim \mathrm{Beta}\Big(\tfrac{1}{2} + d_k,\ \tfrac{1}{2} + n_k - d_k\Big).$$

4.Intervalles de crédibilité de l'approche Bayésienne de Jeffreys

1. Objectivité

On remplace la décision binaire (rejet/non-rejet) par une mesure de crédibilité (degré de soutien) face aux données.

4.Intervalles de crédibilité de l'approche Bayésienne de Jeffreys

1. Objectivité

On remplace la décision binaire (rejet/non-rejet) par une mesure de crédibilité (degré de soutien) face aux données.

2. Intervalle de crédibilité

Un intervalle $[a, b]$ au niveau $(1 - \alpha)$ est défini par la probabilité a posteriori :

$$\mathbb{P}(p_k \in [a, b] \mid y) = 1 - \alpha$$

4.Intervalles de crédibilité de l'approche Bayésienne de Jeffreys

1. Objectivité

On remplace la décision binaire (rejet/non-rejet) par une mesure de crédibilité (degré de soutien) face aux données.

2. Intervalle de crédibilité

Un intervalle $[a, b]$ au niveau $(1 - \alpha)$ est défini par la probabilité a posteriori :

$$\mathbb{P}(p_k \in [a, b] \mid y) = 1 - \alpha$$

3. Interprétation directe

« Compte tenu des données observées, il y a une probabilité de $1 - \alpha$ *que le vrai paramètre* p_k *se situe dans* $[a, b]$*. »*

5.Facteur de Bayes : Alternative à la p-value

Pour comparer H_0 et H_1, Jeffreys utilise le **facteur de Bayes** :

$$BF_{10} = \frac{\pi(y \mid H_1)}{\pi(y \mid H_0)}.$$

où la **vraisemblance marginale** (evidence) est :

$$\pi(y \mid H_k) = \int \pi(y \mid p_k, H_k)\, \pi(p_k \mid H_k)\, dp_k$$

Interprétation :

- $BF_{10} > 1$: soutien en faveur de H_1.
- $BF_{10} < 1$: soutien en faveur de H_0.

Conclusion : p-value et crédibilité bayésienne ne répondent pas à la même question.

Application à la validation des modèles de PD

2. Intervalles de crédibilité pour la calibration

Objectif : vérifier si la PD_k du modèle est compatible avec la distribution a posteriori de p_k.

2. Intervalles de crédibilité pour la calibration

Objectif : vérifier si la PD_k du modèle est compatible avec la distribution a posteriori de p_k.

1. Intervalle unilatéral (Test de surestimation)

On construit la borne supérieure c_α telle que :

$$\mathbb{P}(p_k \leq c_\alpha \mid y) = 1 - \alpha$$

où

$$c_\alpha = \mathrm{F}^{-1}_{Beta}(1-\alpha;\ \tfrac{1}{2} + d_k,\ \tfrac{1}{2} + n_k - d_k)$$

Décision : Si $\mathrm{PD}_k \in]c_\alpha, 1]$, la PD du modèle est **trop élevée** (surestimation du risque).

2. Intervalles de crédibilité pour la calibration

Objectif : vérifier si la PD_k du modèle est compatible avec la distribution a posteriori de p_k.

1. Intervalle unilatéral (Test de surestimation)

On construit la borne supérieure c_α telle que :

$$\mathbb{P}(p_k \leq c_\alpha \mid y) = 1 - \alpha$$

où

$$c_\alpha = \mathrm{F}^{-1}_{Beta}(1-\alpha;\ \tfrac{1}{2} + d_k,\ \tfrac{1}{2} + n_k - d_k)$$

Décision : Si $\mathrm{PD}_k \in]c_\alpha, 1]$, la PD du modèle est **trop élevée** (surestimation du risque).

2. Intervalle bilatéral (ETCI)

On cherche $[p_L, p_U]$ tels que :

$$\Pr(p_k \leq p_L) = \tfrac{\alpha}{2}, \quad \Pr(p_k \geq p_U) = \tfrac{\alpha}{2}$$

où

$$p_L = \mathrm{F}^{-1}_{Beta}(\tfrac{\alpha}{2};\ \tfrac{1}{2} + d_k,\ \tfrac{1}{2} + n_k - d_k)$$
$$p_U = \mathrm{F}^{-1}_{Beta}(1-\tfrac{\alpha}{2};\ \tfrac{1}{2} + d_k,\ \tfrac{1}{2} + n_k - d_k)$$

Décision : Si $\mathrm{PD}_k \notin [p_L, p_U]$, la calibration est **suspecte**.

3. Test de Jeffreys (usage prudentiel) : P-value bayésienne

Idée BCE : quantifier le conservatisme de la PD calibrée, plutôt qu'une décision binaire purement fréquentiste.

3. Test de Jeffreys (usage prudentiel) : P-value bayésienne

Idée BCE : quantifier le conservatisme de la PD calibrée, plutôt qu'une décision binaire purement fréquentiste.

Hypothèses unilatérales :

$$H_0 : p_k \leq \mathrm{PD}_k \qquad \text{vs} \qquad H_1 : p_k > \mathrm{PD}_k.$$

p-value bayésienne

$$\text{p-value}_k = \mathbb{P}(p_k \leq \mathrm{PD}_k \mid y).$$

- **p-value élevée** : forte probabilité que le modèle soit prudent ($p_k \leq \mathrm{PD}_k$).
- **p-value faible** (p-value $< 1 - \alpha$) : risque de sous-estimation (le vrai p_k pourrait dépasser PD_k)

Illustration empirique sous python

0. Présentation des Données : Le Dataset HMEQ

Code de chargement de la base

```
                    import pandas as pd
                    import numpy as np
                    import os
                    import kagglehub
                    from imblearn.under_sampling
    import RandomUnderSampler

                    # 1. Telecharger le dataset (
    Kaggle)
                    path = kagglehub.
    dataset_download("ajay1735/hmeq-data")

                    # 2. Trouver le fichier CSV
                    csv_path = os.path.join(path, "
    hmeq.csv")

                    # 3. Creation du DataFrame
                    df = pd.read_csv(csv_path)

                    # Aper u
                    print(f"Dimensions : {df.shape}
    ")
                    print(df.head())
```

0. Présentation des Données : Le Dataset HMEQ

Code de chargement de la base

```
import pandas as pd
import numpy as np
import os
import kagglehub
from imblearn.under_sampling import RandomUnderSampler

# 1. Telecharger le dataset (Kaggle)
path = kagglehub.dataset_download("ajay1735/hmeq-data")

# 2. Trouver le fichier CSV
csv_path = os.path.join(path, "hmeq.csv")

# 3. Creation du DataFrame
df = pd.read_csv(csv_path)

# Aper u
print(f"Dimensions : {df.shape}")
print(df.head())
```

Dictionnaire des Variables

Variables	Description (FR)
BAD	Cible : 1 = Défaut, 0 = Remboursé
LOAN	Montant de la demande de prêt
MORTDUE	Montant dû sur hypothèque existante
VALUE	Valeur du bien immobilier actuel
REASON	Motif (Conso. dette / Amélioration)
JOB	Catégorie professionnelle (6 types)
YOJ	Années dans l'emploi actuel
DEROG	Nb rapports défavorables majeurs
DELINQ	Nb lignes de crédit en retard
CLAGE	Âge de la plus ancienne ligne (mois)
NINQ	Nb lignes de crédit récentes
CLNO	Nombre total de lignes de crédit
DEBTINC	Ratio Dette / Revenu

Note : Le dataset *Home Equity* (HMEQ) contient des données de comportement de crédit immobilier pour 5 960 prêts récents.

1. Entraînement final

```
                    # Entrainement
    final
                    np.random.seed
    (123)
                    irb_model =
    LogisticRegression(max_iter=1000)
                    irb_model.fit(
    X_train_final, y_train)

                    # Recuperation des
     coefficients
                    # (
    Interpretabilite)
                    coefficients = pd.
    DataFrame({
                        'Variable':
    selected_features,
                        'Coefficient':
     irb_model.coef_[0]
                    }).sort_values(by=
```

1. Etape 1 IRB : différenciation du risque

1. Entraînement final

```
                    # Entrainement final
                    np.random.seed(123)
                    irb_model = LogisticRegression(max_iter=1000)
                    irb_model.fit(X_train_final, y_train)

                    # Recuperation des coefficients
                    # (Interpretabilite)
                    coefficients = pd.DataFrame({
                        'Variable': selected_features,
                        'Coefficient': irb_model.coef_[0]
                    }).sort_values(by=
```

2. PD i de l'echantillon dev

```
                    import pandas as pd
                    from scipy.stats import chi2_contingency, kruskal

                    X_dev = pd.concat([X_train, X_test]).reindex(
                    columns=X_train_final.columns,
                    fill_value=0)

                    # 1. Recreation de la reponse (y)
                    y_dev_actual = pd.concat([y_train, y_test])

                    # 2. Calcul des PD (Score)
                    # Sur l'ensemble de developpement (90%)
```

2. Etape 2 IRB : Quantification du risque

1. Création des Classes (qcut)

```
                    # 2. Creation des
    classes de risque
                    # SANS labels pour
     avoir les intervalles
                    # retbins=True ->
    recupere les coupures
                    np.random.seed
    (123)
                    risk_series, bins
    = pd.qcut(pd_dev, q=4, retbins=
    True)


                    # 3. Creation du
    DataFrame de synthese
                    df_groups = pd.
    DataFrame({
                        'PD_Predite':
    pd_dev,
                    'Classe_Risque
    ': risk_series,
```

2. Etape 2 IRB : Quantification du risque

1. Création des Classes (qcut)

```
                    # 2. Creation des classes de risque
                    # SANS labels pour avoir les intervalles
                    # retbins=True -> recupere les coupures
                    np.random.seed(123)
                    risk_series, bins = pd.qcut(pd_dev, q=4, retbins=True)


                    # 3. Creation du DataFrame de synthese
                    df_groups = pd.DataFrame({
                        'PD_Predite': pd_dev,
                        'Classe_Risque': risk_series,
```

2. Résumé par Classe

```
                    import pandas as pd

                    # 1. Calcul du resume combine
                    # 'Defaut_Reel' -> Realite
                    # 'PD_Predite'  -> Calibration
                    summary = df_groups.groupby('Classe_Risque', observed=True).agg({
                        'Defaut_Reel': ['sum', 'count', 'mean'],
                        'PD_Predite': 'mean'})

                    # 2. Nettoyage des colonnes
                    summary.columns =
```

3. Etape 3 IRB Backtesting : Intervalles de confiance et de crédibilité

Calcul des Intervalles bilatéralles

```
                    from scipy.stats import beta
    , norm

                    def get_bilateral_metrics(k,
     n, PDk, alpha=0.05):

                    if n == 0: return [np.nan] *
     6
                    p_hat = k / n
                    z = norm.ppf(1 - alpha/2)

                    # 1. Approximation Normale (
    Wald)
                    se = np.sqrt((PDk * (1 - PDk
    )) / n)
                    norm_low, norm_high = max(0,
     p_hat - z * se), min(1, p_hat + z * se)

                    # 2. Clopper-Pearson (Exact)
                    cp_low = beta.ppf(alpha/2, k
    , n - k + 1) if k > 0 else 0
                    cp_high = beta.ppf(1 - alpha
    /2, k + 1, n - k) if k < n else 1

                    # 3. Jeffreys (Calibration)
                    jef_low = beta.ppf(alpha/2,
    k + 0.5, n - k + 0.5)
                    jef_high = beta.ppf(1 -
    alpha/2, k + 0.5, n - k + 0.5)

                    return norm_low, norm_high,
```

3. Etape 3 IRB Backtesting : Intervalles de confiance et de crédibilité

Calcul des Intervalles bilatéraux

```
                from scipy.stats import beta
, norm

                def get_bilateral_metrics(k,
 n, PDk, alpha=0.05):

                if n == 0: return [np.nan] *
 6
                p_hat = k / n
                z = norm.ppf(1 - alpha/2)

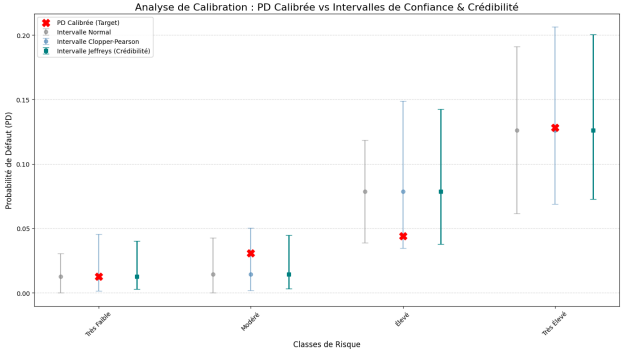
                # 1. Approximation Normale (
Wald)
                se = np.sqrt((PDk * (1 - PDk
)) / n)
                norm_low, norm_high = max(0,
 p_hat - z * se), min(1, p_hat + z * se)

                # 2. Clopper-Pearson (Exact)
                cp_low = beta.ppf(alpha/2, k
, n - k + 1) if k > 0 else 0
                cp_high = beta.ppf(1 - alpha
/2, k + 1, n - k) if k < n else 1

                # 3. Jeffreys (Calibration)
                jef_low = beta.ppf(alpha/2,
k + 0.5, n - k + 0.5)
                jef_high = beta.ppf(1 -
alpha/2, k + 0.5, n - k + 0.5)

                return norm_low, norm_high,
```

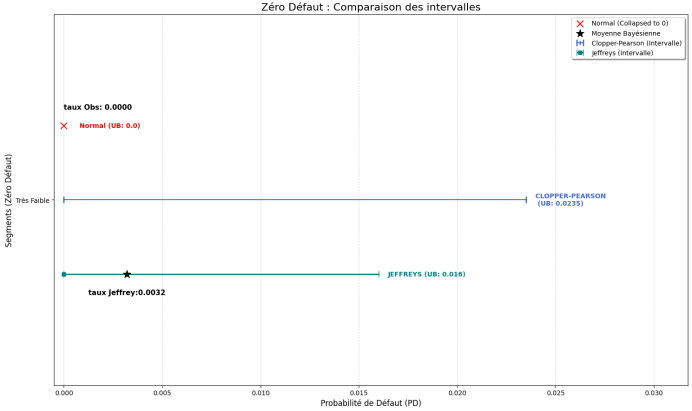
Visualisation des résultats



Interprétation du graphique :

- **X (Rouge)** : La PD cible à valider.
- **Clopper-Pearson (Bleu)** : Intervalle très large, souvent trop prudent.
- **Jeffreys (Vert)** : Plus précis (plus court), c'est la métrique de référence BCE.

Analyse Graphique du "Crash Test" : Le Cas Zéro Défaut (LDP)



Interprétation du graphique :

1. Approche Normale

✗ Borne : **0.0%**

✗ **Danger :** Aveugle au risque latent

2. Clopper-Pearson

➜ Trop large (2.35%)

➜ Surcharge inutile de capital

3. Jeffreys (Validé)

✓ Prior intelligent

✓ **Validation avec Précision optimale**

Etape 3 IRB Backtesting : P-Value Bayésien

Calcul de la p-value

```
                    from scipy.stats import beta
                    import numpy as np

                    def get_jeffreys_p_value(k, n,
    pd_calib):
                        """
                        P-value unilaterale de Jeffreys
    .
                        H0 : True PD <= pd_calib
                        """
                        if n == 0: return np.nan

                        # Parametres a posteriori (
    Jeffreys)
                        # a = succes + 0.5, b = echecs
    + 0.5
                        a = k + 0.5
                        b = n - k + 0.5

                        # P-value = CDF Beta au point
    PD_calib
                        # Prob(True_PD <= PD_calib |
    Data)
                        p_val = beta.cdf(pd_calib, a, b
    )

                        return p_val
```

Etape 3 IRB Backtesting : P-Value Bayésien

Calcul de la p-value

```python
from scipy.stats import beta
import numpy as np

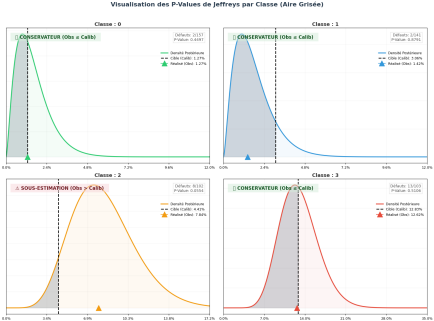
def get_jeffreys_p_value(k, n, pd_calib):
    """
    P-value unilaterale de Jeffreys.
    H0 : True PD <= pd_calib
    """
    if n == 0: return np.nan

    # Parametres a posteriori (Jeffreys)
    # a = succes + 0.5, b = echecs + 0.5
    a = k + 0.5
    b = n - k + 0.5

    # P-value = CDF Beta au point PD_calib
    # Prob(True_PD <= PD_calib | Data)
    p_val = beta.cdf(pd_calib, a, b)

    return p_val
```

Visualisation : Aire de la P-Value



- **Courbe** : Densité a posteriori du taux de défaut.
- **Pointillés** : PD Calibrée du modèle.
- **Aire Grisée (P-value)** : Probabilité que le vrai risque soit inférieur à la prédiction.

Conclusion : Une aire grisée importante (p-value élevée) indique un modèle prudent (conservateur).

Limites du test de Jeffreys et conclusion

Limites du test de Jeffreys

Le test de Jeffreys présente certaines limites intrinsèques :

Limites du test de Jeffreys

Le test de Jeffreys présente certaines limites intrinsèques :

- **Influence de l'a priori de Jeffreys Beta$(0.5, 0.5)$ sur le résultat final en petit échantillon.**

Limites du test de Jeffreys

Le test de Jeffreys présente certaines limites intrinsèques :

- **Influence de l'a priori de Jeffreys Beta$(0.5, 0.5)$ sur le résultat final en petit échantillon.**

- **Complexité d'interprétation (Changement de paradigme) :**
  Raisonnement basé sur la *plausibilité du paramètre* (la PD) et non sur la fréquence des données (contre-intuitivité).

Limites du test de Jeffreys

Le test de Jeffreys présente certaines limites intrinsèques :

- **Influence de l'a priori de Jeffreys Beta$(0.5, 0.5)$ sur le résultat final en petit échantillon.**
- **Complexité d'interprétation (Changement de paradigme) :**
  Raisonnement basé sur la *plausibilité du paramètre* (la PD) et non sur la fréquence des données (contre-intuitivité).
- **Convergence asymptotique des trois méthodes de validation :**
  "Pas de valeur ajoutée" hors des contextes LDP.

Conclusion Générale

Ce projet met en évidence la supériorité de l'approche de Jeffreys pour la validation des modèles de risque en contexte de données rares (LDP) :

Conclusion Générale

Ce projet met en évidence la supériorité de l'approche de Jeffreys pour la validation des modèles de risque en contexte de données rares (LDP) :

- **Réponse au défi des "Zéro Défaut" :**
  Maintient une vigilance statistique même en 0 défaut grâce à son a priori bayésien.

Conclusion Générale

Ce projet met en évidence la supériorité de l'approche de Jeffreys pour la validation des modèles de risque en contexte de données rares (LDP) :

- **Réponse au défi des "Zéro Défaut" :**
  Maintient une vigilance statistique même en 0 défaut grâce à son a priori bayésien.

- **Le Compromis Idéal :**
  Offre un compromis optimal entre le conservatisme excessif de Clopper-Pearson (coûteux) et le laxisme des méthodes asymptotiques (dangereux).

Conclusion Générale

Ce projet met en évidence la supériorité de l'approche de Jeffreys pour la validation des modèles de risque en contexte de données rares (LDP) :

- **Réponse au défi des "Zéro Défaut" :**
  Maintient une vigilance statistique même en 0 défaut grâce à son a priori bayésien.

- **Le Compromis Idéal :**
  Offre un compromis optimal entre le conservatisme excessif de Clopper-Pearson (coûteux) et le laxisme des méthodes asymptotiques (dangereux).

- **Enjeu Économique (Capital Management) :**
  Permet de limiter l'immobilisation inutile de fonds propres tout en garantissant leur solvabilité face au régulateur (BCE).